

7. 贝叶斯分类器

余伟浩

whyu@whyu.me

中山大学AI技术俱乐部
《机器学习》课程



HCP

Human Cyber Physical Intelligence
Integration Lab @ SYSU
中山大学人机物智能融合实验室

Our laboratory seeks general and task-driven ways to build intelligence,
embracing the access to the ternary human-cyber-physical universe.



参考课本：周志华. (2016). 机器学习. 清华大学出版社.

何为分类器

x为输入，c为类别（class）



对于各个模型，明确输入输出才不会乱

思路

- 7. 贝叶斯分类器
 - 区别：
 - 贝叶斯分类器：通过最大后验概率进行单点估计
 - 贝叶斯学习：通过最大后验概率进行分布估计
 - 7.0 入门知识（补充）
 - 贝叶斯定理
 - 相互独立
 - 判别式与生成式模型
 - 期望
 - 7.1 贝叶斯决策论
 - 7.2 极大似然估计（不讲）
 - 7.3 朴素贝叶斯分类器
 - 7.4 半朴素贝叶斯分类器
 - 7.5 贝叶斯网络

7.0 入门知识（补充）

已知：


$$P(A) = 1/2$$

$$P(B|A) = 1/3$$

$$P(B) = 1/3$$


$$P(A|B) = 1/2$$

求 $P(A, B)$ ？




贝叶斯定理

- $P(A, B) = P(A) \times P(B|A)$
- $P(A, B) = P(B) \times P(A|B)$
- 又因为 $P(A, B) = P(A, B)$
- 所以:
- $P(A) \times P(B|A) = P(B) \times P(A|B)$
- 所以 $P(A)$, $P(B|A)$, $P(B)$, $P(A|B)$ 四个值, 可以知三求一
- 比如要求 $P(B|A)$, 只需移一下项便可得
- $P(B|A) = \frac{P(B) \times P(A|B)}{P(A)}$
- 上面这个式子便是贝叶斯定理



贝叶斯定理

- 应用题：
- 上海交大武筱林教授的论文《基于面部图像的自动犯罪性概率推断》（Automated Inference on Criminality using Face Images）



已知中国的犯罪率是0.36%，请问当被模型检测出犯罪，实际有罪犯的概率有多大？

←左边还有

$$N=0.9964$$

S

←左边还有

$$N=0.9964$$

←左边还有

$$N=0.9964$$

←左边还有

$$N=0.9964$$

4.39%



已知：

$$P(A) = 1/2$$

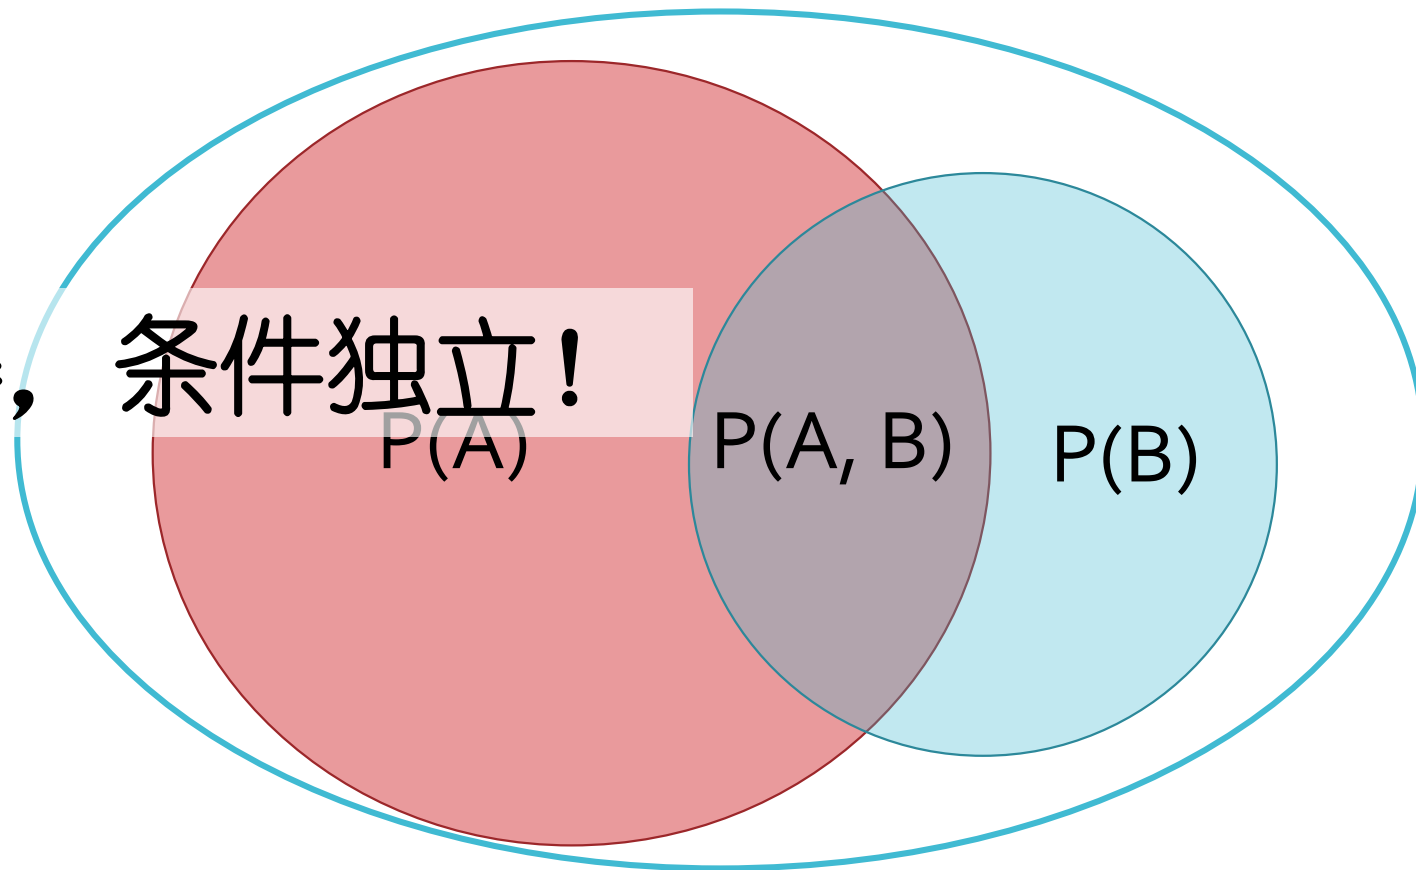
$$P(B|A) = 1/3$$

$$P(B) = 1/3$$

$$P(A|B) = 1/2$$

相等，条件独立！

求 $P(A, B)$ ？



已知：

$$P(A) = 1/2$$

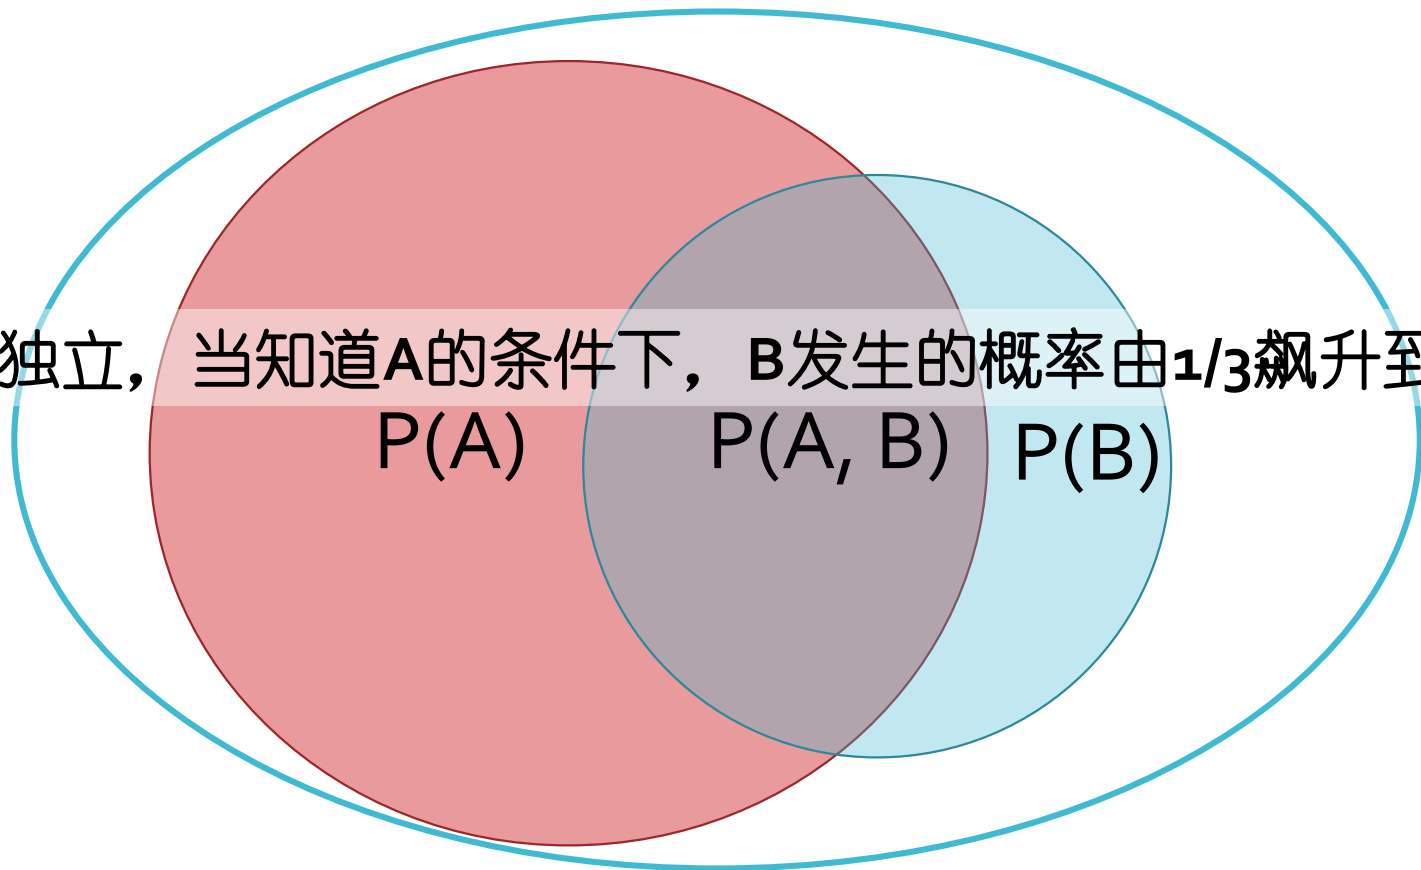
$$P(B|A) = 1/2$$

$$P(B) = 1/3$$

$$P(A|B) = 3/4$$

求 $P(A, B)$ ？

条件不独立，当知道A的条件下，B发生的概率由 $1/3$ 飙升到 $1/2$

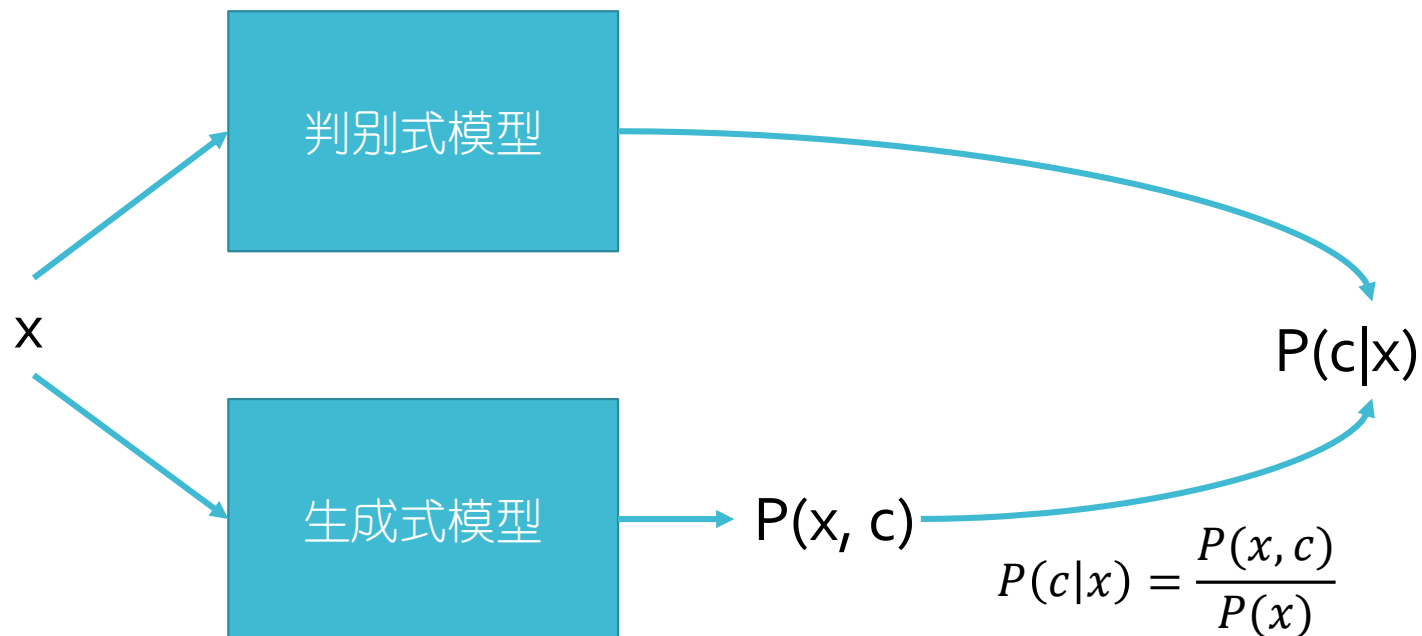


相互独立

- $P(A, B) = P(A) \times P(B|A) = P(A) \times P(B)$
- $P(A, B) = P(B) \times P(A|B) = P(B) \times P(A)$
- 所以A, B相互独立的条件为
- $P(A, B) = P(A) \times P(B)$
- 推广到多维
- $P(A, B, C, D \dots) = P(A) \times P(B) \times P(C) \times P(D) \times \dots$
- 推广到条件概率
- $P(A, B, C, D \dots | Y) = P(A|Y) \times P(B|Y) \times P(C|Y) \times P(D|Y) \times \dots$

判别式与生成式模型

x是输入，c是标签



总结：在分类任务中，
判别式模型：一步到位，直接输出 $P(c|x)$ ，模型中间运算不会出现 $P(x, c)$
生成式模型：两步走，先算出 $P(x, c)$ ，再由概率公式算出 $P(c|x)$

期望

- 例子：
- 买一张彩票金额为1元，中奖奖金1000元，中奖率万分之一，请问选择买一张彩票得到的奖金期望是多少？不买彩票得到的奖金期望是多少？

期望

- 例子：
- 买一张彩票金额为1元，中奖奖金1000元，中奖率万分之一，请问选择买一张彩票得到的奖金期望是多少？不买彩票得到的奖金期望是多少？
- $E(\text{买彩票}) = -1 * 0.9999 + (1000 - 1) * 0.0001 = -0.9$
- $E(\text{不买彩票}) = 0 * 0.9999 + 0 * 0.0001 = 0$

期望

- 例子:
- 买一张彩票金额为1元，中奖奖金1000元，中奖率万分之一，请问选择买一张彩票得到的奖金期望是多少？不买彩票得到的奖金期望是多少？
- $E(\text{买彩票}) = -1 * 0.9999 + (1000 - 1) * 0.0001 = -0.9$
- $E(\text{不买彩票}) = 0 * 0.9999 + 0 * 0.0001 = 0$
- 转换成矩阵预算

奖励矩阵	不中奖 中奖	
	买	不买
	$\begin{bmatrix} -1 & 999 \\ 0 & 0 \end{bmatrix}$	

期望

- 例子:
- 买一张彩票金额为1元，中奖奖金1000元，中奖率万分之一，请问选择买一张彩票得到的奖金期望是多少？不买彩票得到的奖金期望是多少？
- $E(\text{买彩票}) = -1 * 0.9999 + (1000 - 1) * 0.0001 = -0.9$
- $E(\text{不买彩票}) = 0 * 0.9999 + 0 * 0.0001 = 0$
- 转换成矩阵预算

奖励矩阵		不中奖	中奖
	买 不买	$\begin{bmatrix} -1 & 999 \\ 0 & 0 \end{bmatrix}$	

概率矩阵	不中奖 中奖	$\begin{bmatrix} 0.9999 \\ 0.0001 \end{bmatrix}$
------	-----------	--

期望	$\begin{bmatrix} E(\text{买}) \\ E(\text{不买}) \end{bmatrix} = \begin{bmatrix} -1 & 999 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 0.9999 \\ 0.0001 \end{bmatrix} = \begin{bmatrix} -0.9 \\ 0 \end{bmatrix}$
----	--

7.1 贝叶斯决策论

何为贝叶斯决策理论？

- 天气预报明天
- 30%的概率下雨
- 60%的概率阴天
- 10%的概率晴天
- 我要选择明天天气情况（决定了我要不要带雨伞）
-

何为贝叶斯决策论？

- 天气预报明天
 - 30%的概率下雨
 - 60%的概率阴天
 - 10%的概率晴天
-
- 我要选择明天天气情况（决定了我要不要带雨伞）
 - 贝叶斯理决策理论：给定概率做决策

贝叶斯决策论

输入

$P_1 = XX \%$

$P_2 = XX \%$

$P_3 = XX \%$

$P_4 = XX \%$

.....

$$\sum_n P_n = 1$$

贝叶斯决策
论

输出

选择

贝叶斯决策论

0代表猫，1代表狗

$$p(c=0|x) = 0.9$$

$$P(c=1|x) = 0.1$$

基于概率的
决策模型

$c = ?$



x

假如这个决策模型就是你的大脑，给定了以上概率，你是选择“猫”还是“狗”？

贝叶斯决策论

假设我们去医院做检查
拍了B超照片后B超机器给出了以下概率

0代表正常，1代表癌症

$$p(c=0|x) = 0.9$$

$$P(c=1|x) = 0.1$$

基于概率的
决策模型

$c = ?$



X

我们是选择 $c=0$, 回家洗洗睡
还是选择 $c=1$, 请人类医生再进一步检查呢
对比上一页ppt的猫狗问题, 同样0.9, 0.1的概率分布, 选择却不一样? 怎样对不同情况进行建模?

贝叶斯决策论

要计算损失期望，有必要引入损失矩阵

对于猫狗问题

实际 选择	猫	狗
猫	0	1
狗	1	0

选择猫的损失期望值为

$$R(0|x) = 0 \times P(0|x) + 1 \times P(1|x) = 0 \times 0.9 + 1 \times 0.1 = 0.1$$

选择狗的损失期望值为

$$R(1|x) = 1 \times P(0|x) + 0 \times P(1|x) = 1 \times 0.9 + 0 \times 0.1 = 0.9$$

对于癌症问题

实际 选择	无癌症	癌症
无癌症	0	10000
癌症	1	0

选择无癌症的损失期望值为

$$R(0|x) = 0 \times P(0|x) + 10000 \times P(1|x) = 0 \times 0.9 + 10000 \times 0.1 = 1000$$

选择癌症的损失期望值为

$$R(1|x) = 1 \times P(0|x) + 0 \times P(1|x) = 1 \times 0.9 + 0 \times 0.1 = 0.9$$

贝叶斯决策论

对于癌症问题

选择 \ 实际	无癌症	癌症
无癌症	0	10000
癌症	1	0

多样本

$$x^1 \begin{cases} P(y=0|x^1) = 0.9 \\ p(y=1|x^1) = 0.1 \end{cases}$$

$$x^2 \begin{cases} P(y=0|x^2) = 0.99 \\ p(y=1|x^2) = 0.01 \end{cases}$$

$$x^3 \begin{cases} P(y=0|x^3) = 0.9999 \\ p(y=1|x^3) = 0.0001 \end{cases}$$

$$x^4 \begin{cases} P(y=0|x^4) = 0.99999 \\ p(y=1|x^4) = 0.00001 \end{cases}$$

找判定标准 $X \rightarrow Y$, 使得
对所有样本, 总体损失
最小

$$R_{\text{总}} = R^1 + R^2 + R^3 + R^4$$

找判定标准 $X \rightarrow Y$, 使
得每个个体的损失函
数最小

$$h^*(x) = \arg \min_{c \in Y} R(c|x)$$

贝叶斯决策论

幸运的是，在分类任务中，我们一般遇到的是猫狗问题，损失矩阵为 $1-I$ ，其中 I 为单位矩阵

对于猫狗问题 $1 - \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$

对于猫狗兔问题 $1 - \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 0 & 1 & 1 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix}$

此时条件风险 $R(y=c|x) = 1 - P(y=c|x)$ ，比如猫狗兔问题

$$\begin{array}{l} x \text{ (图片)} \left\{ \begin{array}{l} P(y=\text{猫}|x) = 0.7 \\ p(y=\text{狗}|x) = 0.2 \\ p(y=\text{兔}|x) = 0.1 \end{array} \right. \rightarrow \begin{bmatrix} 0.7 \\ 0.2 \\ 0.3 \end{bmatrix} \rightarrow R = \begin{bmatrix} 0 & 1 & 1 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix} \begin{bmatrix} 0.7 \\ 0.2 \\ 0.3 \end{bmatrix} = \begin{bmatrix} 0.3 \\ 0.8 \\ 0.1 \end{bmatrix}$$

得 $R(y=\text{猫}|x) = 0.3$, $R(y=\text{狗}|x) = 0.8$, $R(y=\text{兔}|x) = 0.1$
所以为了最小化损失期望，应该选择 $y=\text{猫}$

$$h^*(x) = \arg \min_{c \in y} R(c|x) = \arg \min_{c \in y} (1 - P(c|x)) = \arg \max_{c \in y} P(c|x)$$

所以，结论是为了最小化损失期望，选择那个概率最大的。
其实我们一开始就是这么想的。。。这就是贝叶斯决策论！

贝叶斯决策论 总结

输入

$P_1 = XX\%$
 $P_2 = XX\%$
 $P_3 = XX\%$
 $P_4 = XX\%$
.....

$$\sum_n P_n = 1$$

贝叶斯决策
理论

输出

选择

根据损失矩阵计算
损失期望值，选择
使得损失期望值最
小的那个类

说白了就是
算期望，再
比大小

当损失矩阵为1-I时，
选择那个概率最大
的类

这种情况连
期望都不用
算了，直接
比大小

贝叶斯决策论 总结

这些概率要怎么得到？

输入

$P_1 = XX\%$
 $P_2 = XX\%$
 $P_3 = XX\%$
 $P_4 = XX\%$
.....

$$\sum_n P_n = 1$$

贝叶斯决策
理论

输出

选择

根据损失矩阵计算
损失期望值，选择
使得损失期望值最
小的那个类

说白了就是
算期望，再
比大小

当损失矩阵为1-I时，
选择那个概率最大
的类

这种情况连
期望都不用
算了，直接
比大小

贝叶斯决策论 总结

这些概率要怎么得到？

答：利用**概率模型**

输入

$P_1 = XX\%$
 $P_2 = XX\%$
 $P_3 = XX\%$
 $P_4 = XX\%$
.....

$$\sum_n P_n = 1$$

贝叶斯决策
理论

输出

选择

根据损失矩阵计算
损失期望值，选择
使得损失期望值最
小的那个类

说白了就是
算期望，再
比大小

当损失矩阵为1-I时，
选择那个概率最大
的类

这种情况连
期望都不用
算了，直接
比大小

何为概率模型？

x

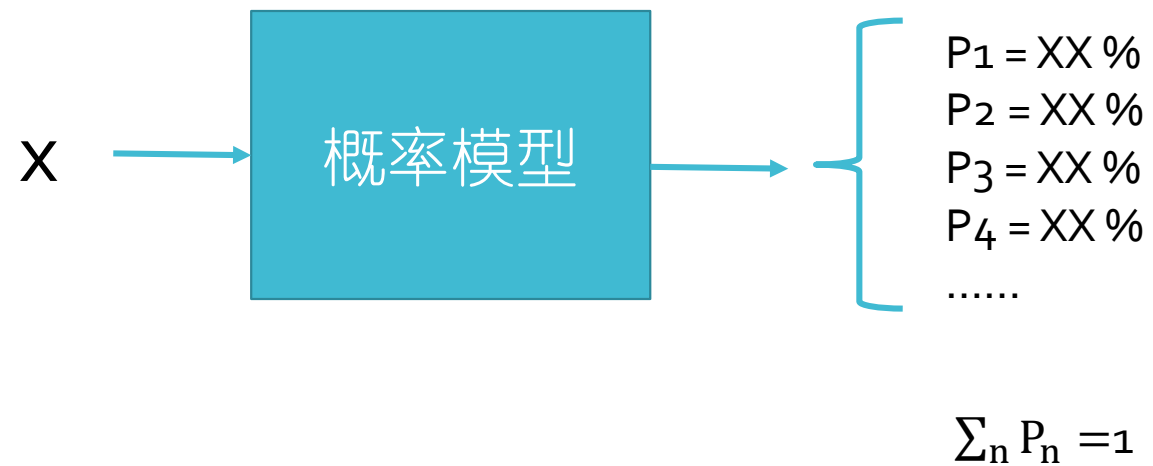


概率模型




输出是什么？

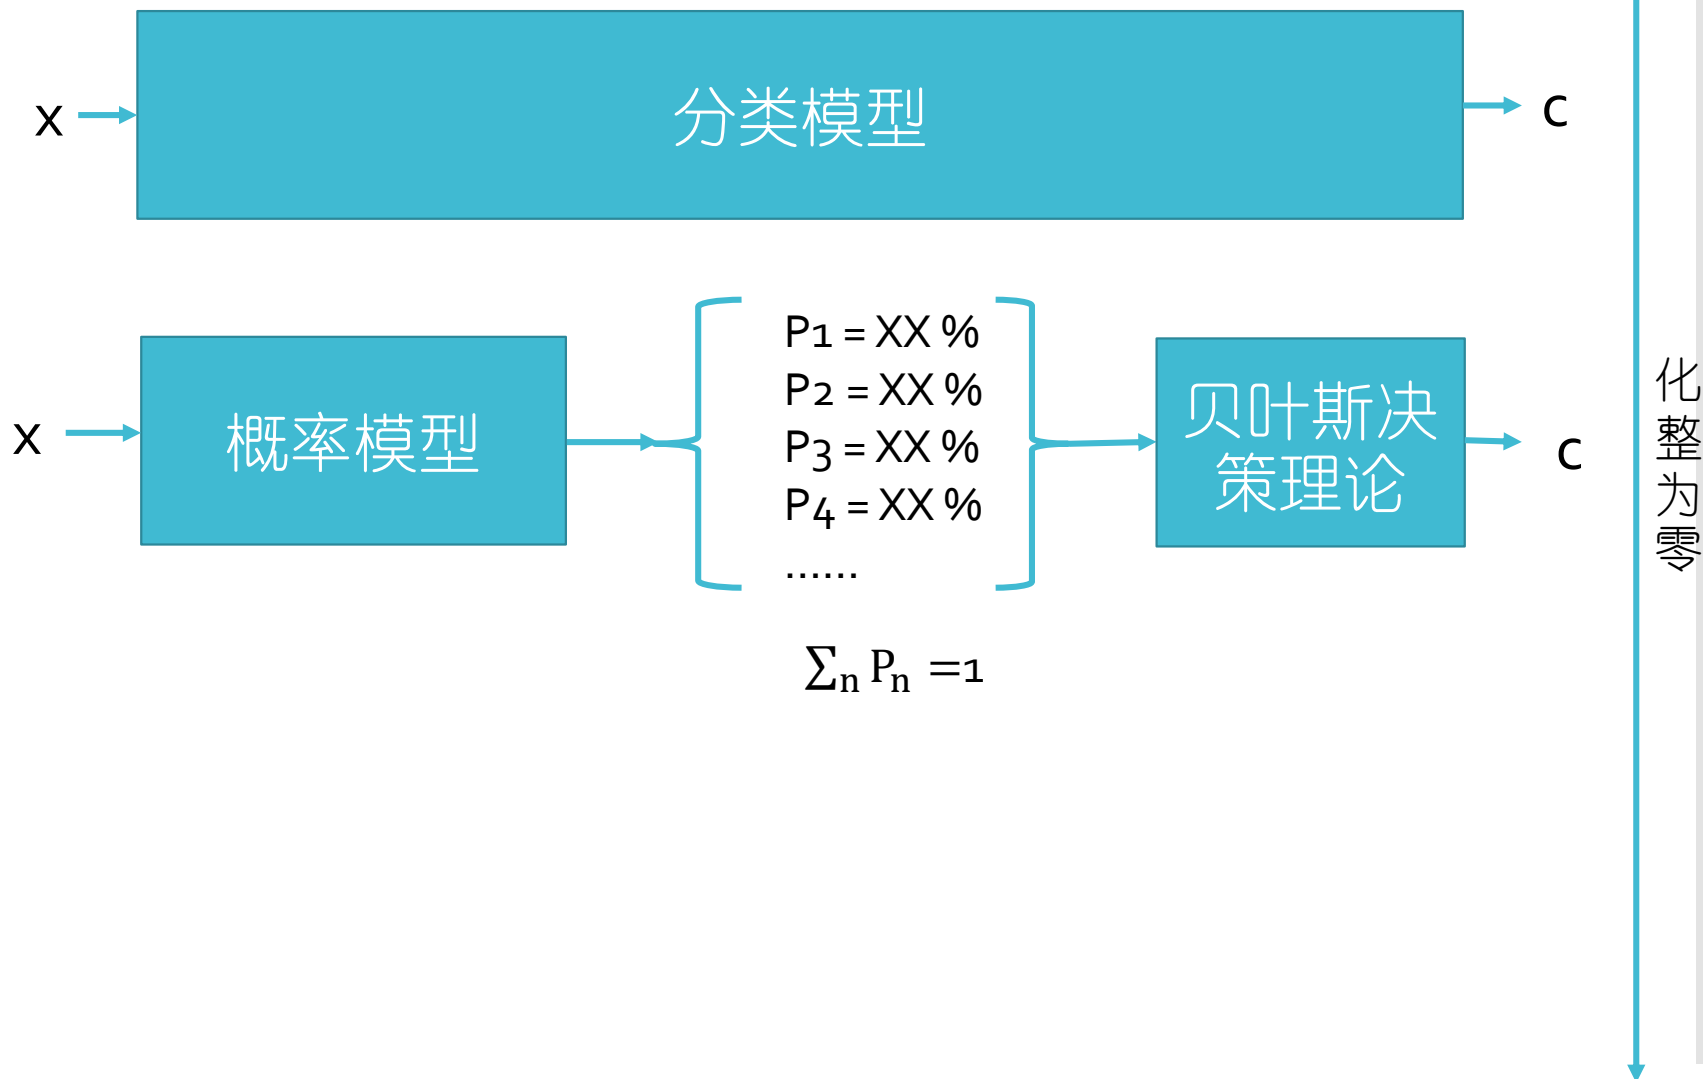
何为概率模型？



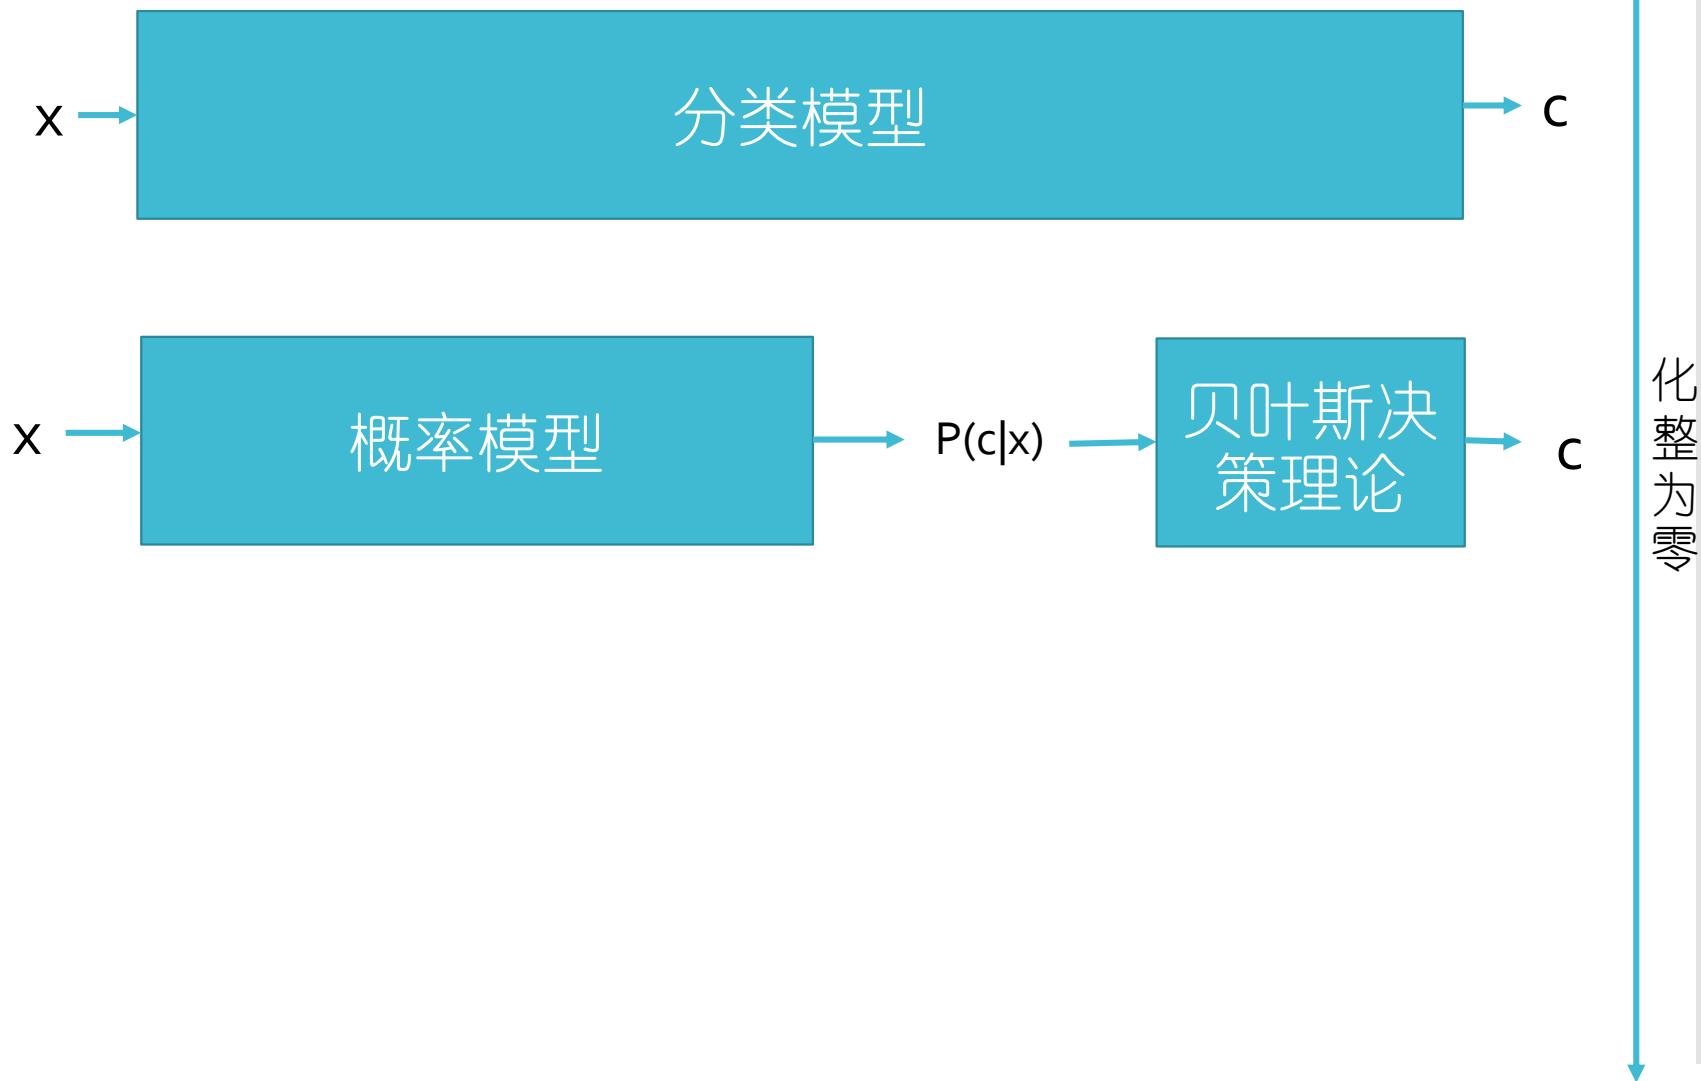
何为概率模型？



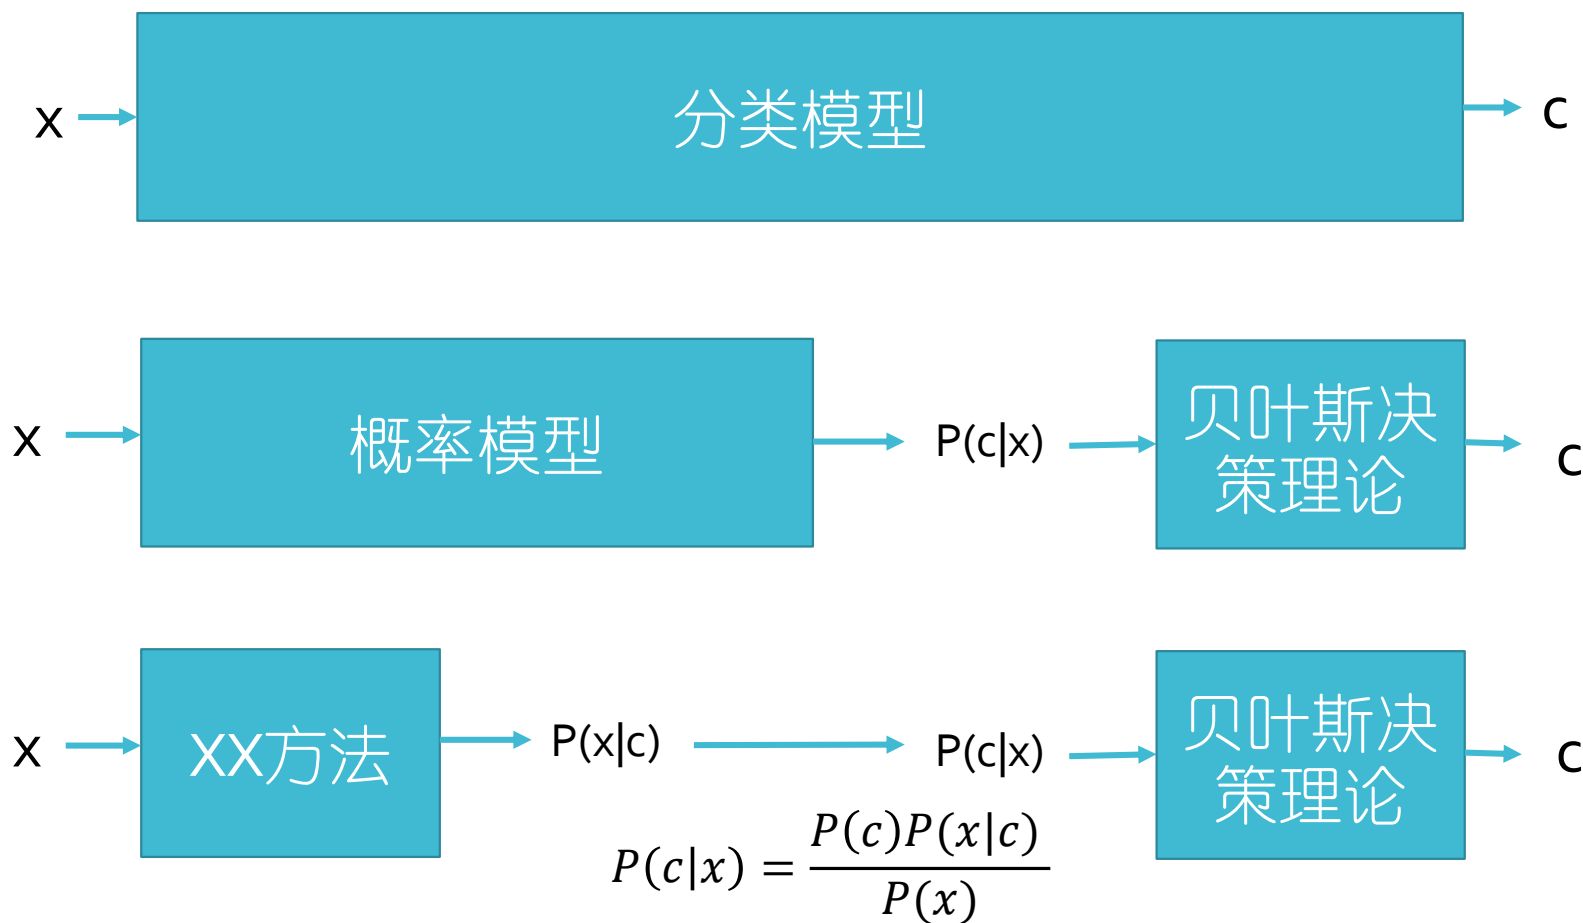
分类器的化整为零



分类器的化整为零

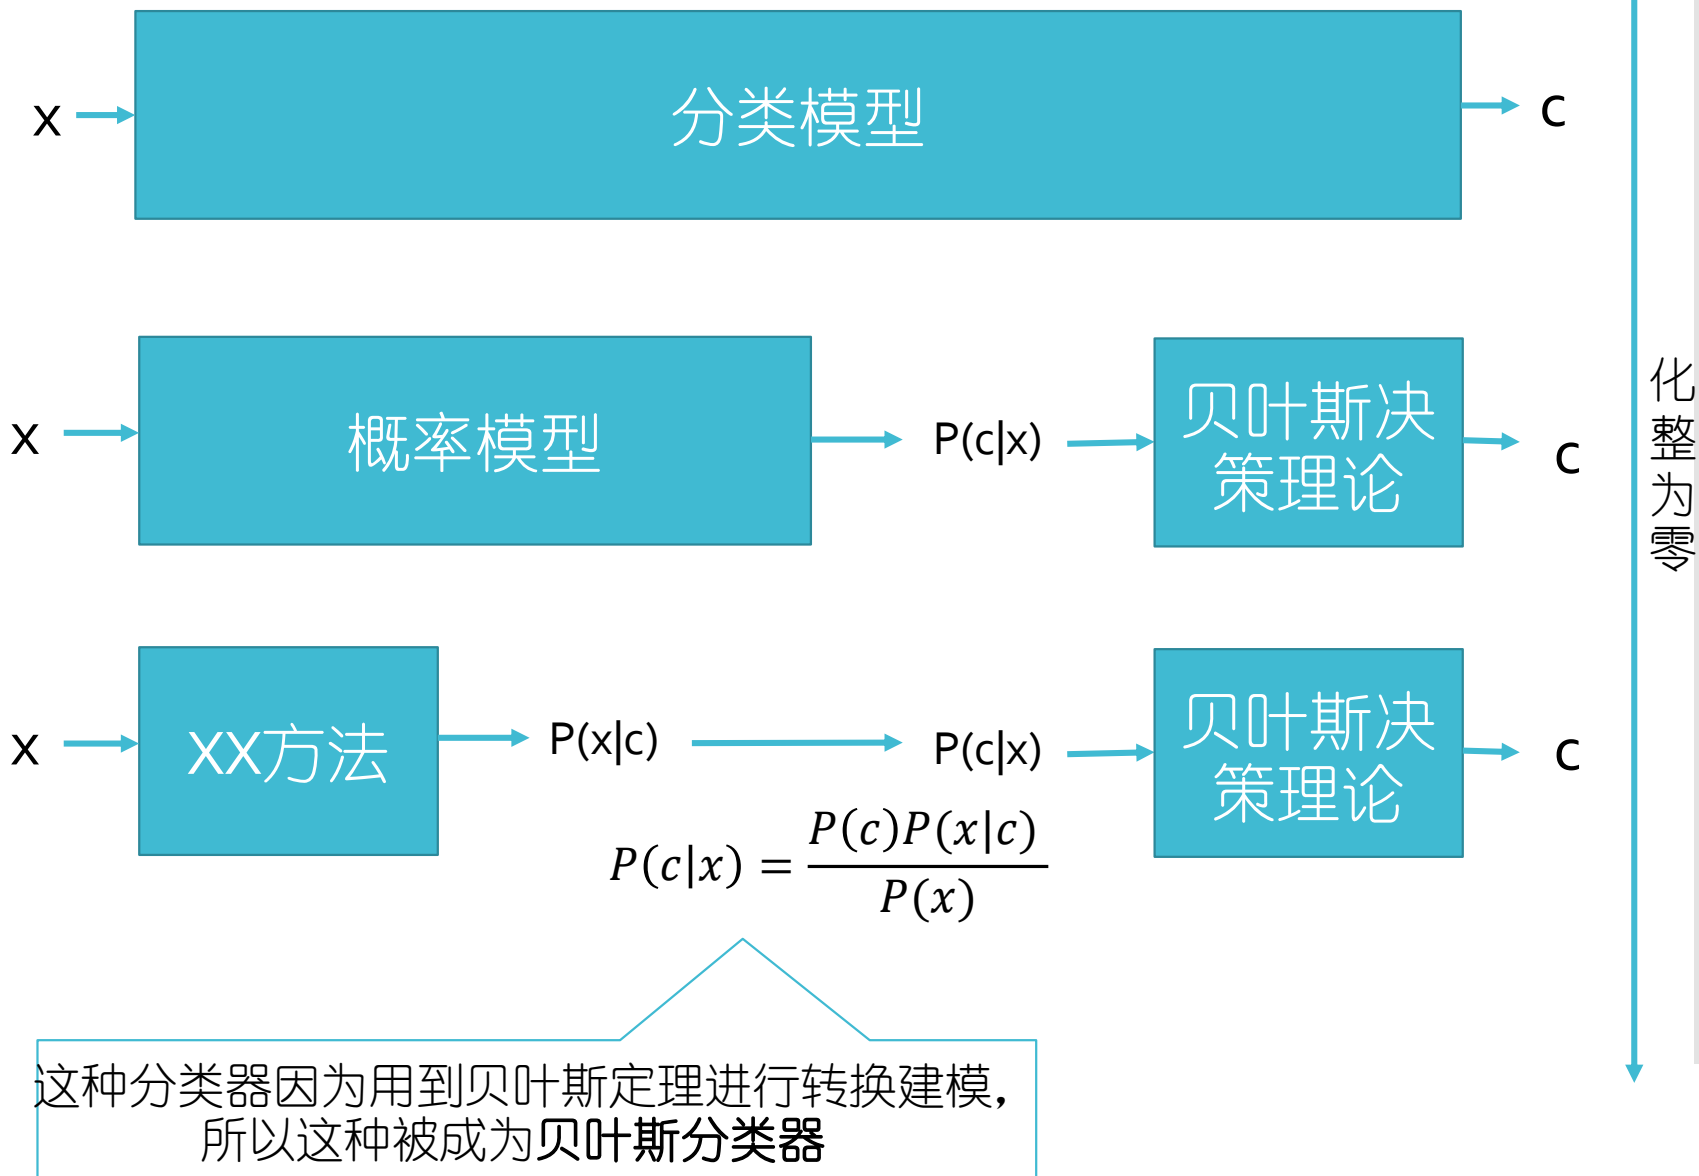


分类器的化整为零





化整为零

分类器的化整为零



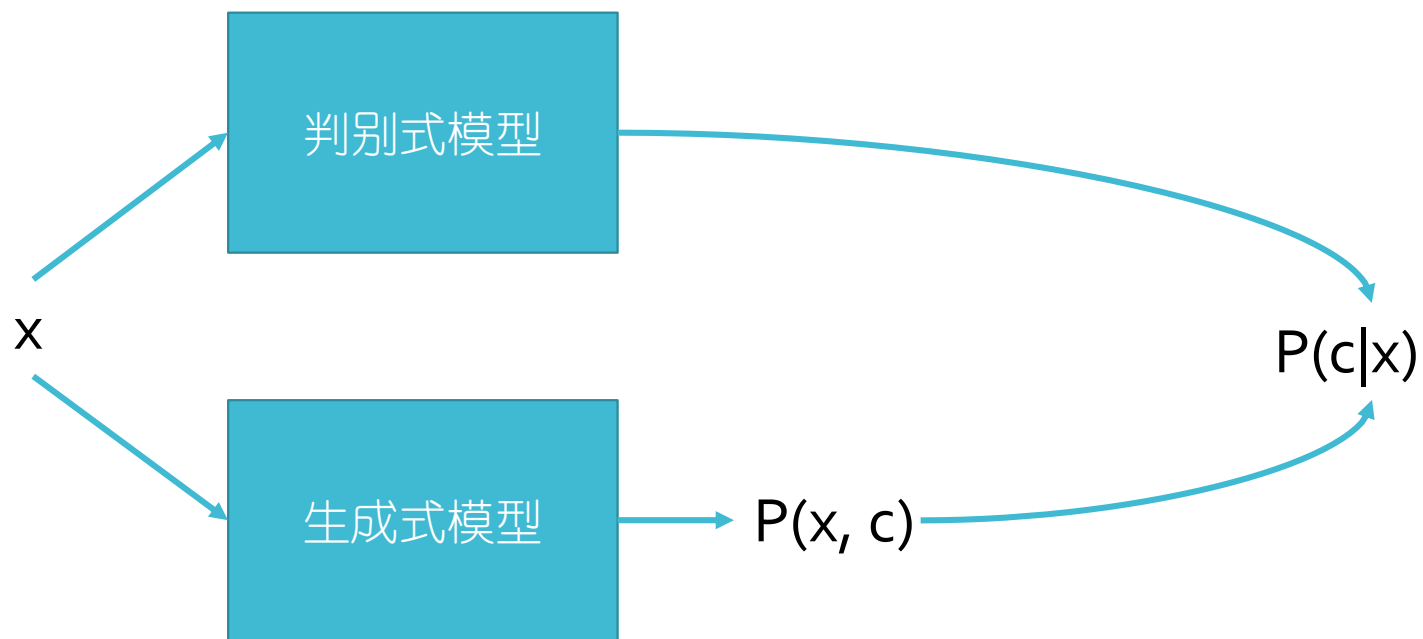

分类器的化整为零

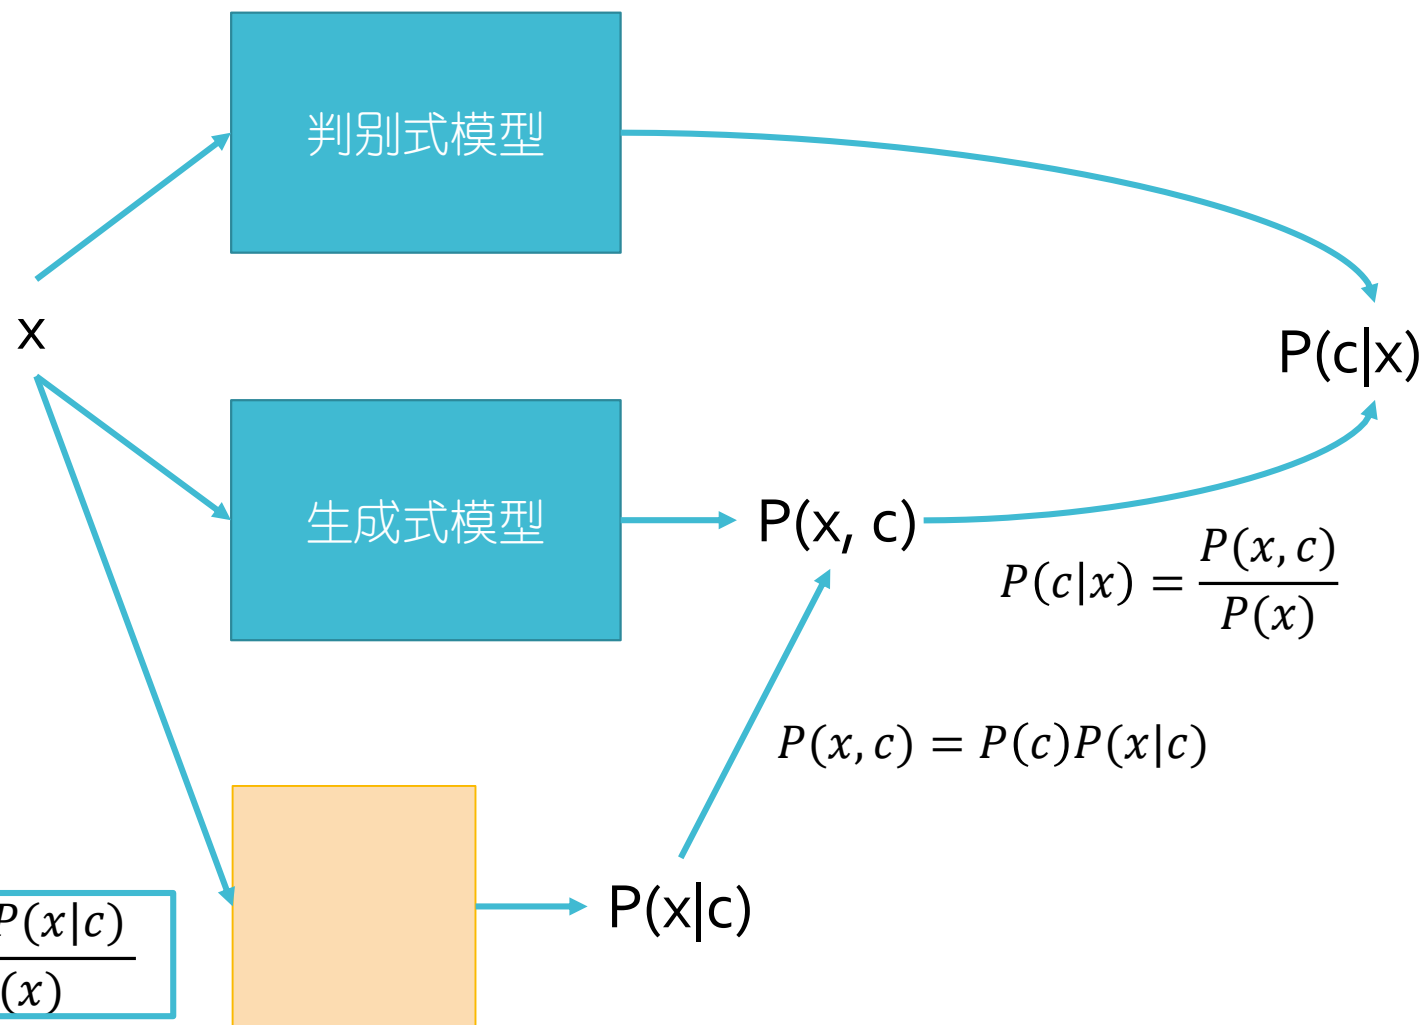



$$P(c|x) = \frac{P(c)P(x|c)}{P(x)}$$

这种分类模型是生成式模型还是判别式模型？

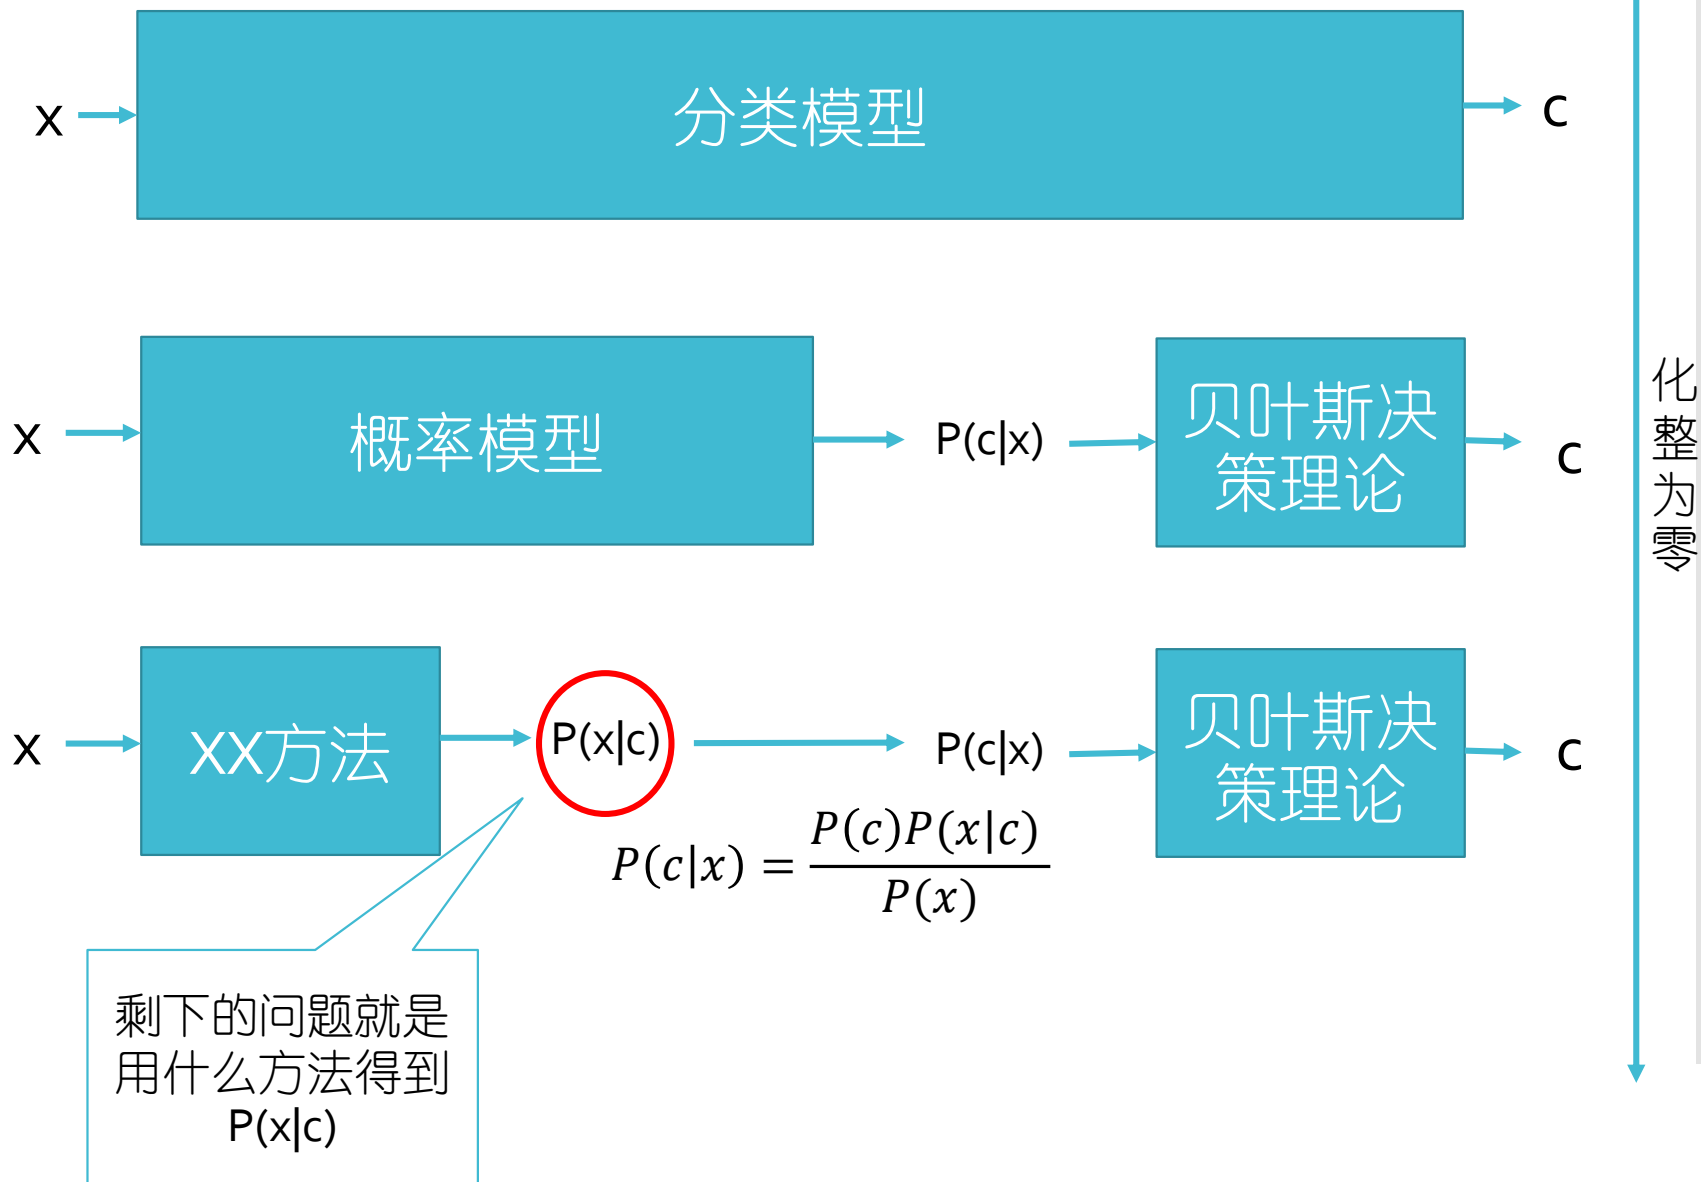
化整为零






贝叶斯定理
$$P(c|x) = \frac{P(x, c)}{P(x)} = \frac{P(c)P(x|c)}{P(x)}$$

分类器的化整为零



加假设条件简化计算



剩下的问题就是
用什么方法得到
 $P(x|c)$

$$x = (x_1, x_2, x_3, x_4, x_5, \dots)$$

$$P(x_1, x_2, x_3, x_4, x_5, \dots | c) = ?$$

强

假设

方法

$x_1, x_2, x_3, x_4, x_5, \dots$ 之间相互独立

$x_1, x_2, x_3, x_4, x_5, \dots$ 之间部分相互依赖

$x_1, x_2, x_3, x_4, x_5, \dots$ 之间任意相互依赖

朴素贝叶斯分类器


半朴素贝叶斯分类器

贝叶斯网路

复杂

7.3 朴素贝叶斯分类器

朴素贝叶斯分类器



剩下的问题就是
用什么方法得到
 $P(x|c)$

$$x = (x_1, x_2, x_3, x_4, x_5, \dots)$$

$$P(x_1, x_2, x_3, x_4, x_5, \dots | c) = ?$$

假设 $x_1, x_2, x_3, x_4, x_5, \dots$ 之间相互独立

$$P(x_1, x_2, x_3, x_4, x_5, \dots | c) = P(x_1|c) * P(x_2|c) * P(x_3|c) * P(x_4|c) * P(x_5|c)$$

请同学们照着周志华老师的《机器学习》的p152-154页的题目演算一遍

7.4 半朴素贝叶斯分类器

半朴素贝叶斯

- 讲课时借用周志华老师的ppt进行讲解，请同学们参照周志华老师的ppt和课本进行复习

7.5 贝叶斯网络

贝叶斯网络

- 讲课时借用周志华老师的ppt进行讲解，请同学们参照周志华老师的ppt和课本进行复习